

黄金殿

大模型应用算法工程师 • Agent / RAG 方向

• 电话: 13522431624

• 邮箱: 13522431624@163.com

• 4年NLP及大模型应用经验

• Agent / RAG / 模型微调项目经验



专业技能

一、Agent 与 workflow 编排

熟悉 LangChain、LangGraph、AutoGen、Dify 等大模型应用开发与 workflow 编排框架，掌握 ReAct、Plan-and-Execute、Self-Ask、CoT、ToT 等 Agent 推理与任务执行模式。能够围绕实际业务需求设计 Agent 工作流，实现任务拆解、工具调用、条件路由、多轮循环、状态管理、记忆管理、异常重试及人工确认等功能。

二、RAG 检索增强技术

1. 熟悉 RAG 检索增强生成系统的完整处理流程，能够将 Text2SQL、LightRAG 与 Neo4j 知识图谱进行整合，构建面向业务场景的智能问答体系。
2. 熟悉 BGE 文本向量化技术，掌握多路召回、粗排、Reranker 精排等检索流程，能够结合向量检索与知识图谱检索提升系统召回效果和回答准确性。熟悉 FAISS、Milvus 等向量数据库的基本使用及应用场景。

三、大模型微调策略

掌握 LoRA、P-Tuning 等参数高效微调技术，熟悉微调数据构造、训练参数配置、模型训练及效果验证流程，具备以下方向的实践经验：

1. 面向垂直领域数据微调大语言模型，提升模型在特定业务场景中的问答准确性和专业性。
2. 面向 Agent 工具调用场景微调大模型，提升模型的任务拆解、工具识别、参数生成和工具选择能力，减少 Agent 出现任务拆分错误及工具选择错误的问题。

四、Vibe Coding 自动编程工具

熟悉 Vibe Coding 开发模式，能够使用 Cursor、Codex、Claude Code 等 AI 编程工具完成需求分析、代码生成、代码调试、问题定位及项目功能迭代，提高开发与工程交付效率。

五、编程语言、数据库与部署

熟练使用 Python 进行项目开发、脚本编写和数据处理，掌握 Linux 常用命令、服务运行、环境配置与日志排查；熟练使用 MySQL、PostgreSQL 和 Neo4j，可根据业务场景完成关系型及图数据的存储与查询；熟悉 Docker Compose 多服务容器化编排、配置和启动，了解 Kubernetes 服务编排、资源管理及应用部署。

六、大模型与多模态核心技术

1. 多模态技术：熟悉 CNN、ViT、CLIP、BLIP 等视觉与图文多模态模型的基本原理，了解图像特征提取、图文对齐及视觉问答流程，能够实现图片内容分析，并结合用户问题生成相应回答。
2. MoE 模型架构：了解 MoE 大模型架构及专家路由机制，熟悉根据输入任务动态选择并激活不同专家组件的基本原理，理解 MoE 在扩展模型参数规模和降低推理计算量方面的作用。

七、数字人与语音交互

具备 ASR、LLM、TTS 与数字人驱动链路的开发经验，熟悉 VAD、SenseVoice、CosyVoice2、MuseTalk、GPT-SoVITS、Live2D、VRM 等相关技术。

能够完成从语音活动检测、语音识别、大模型对话生成、语音合成到数字人口型驱动的端到端链路集成，并具备相关模块接口联调和问题排查经验。

工作经历

北京元予壹软件科技有限公司

NLP 算法工程师

2022.8 - 至今

1. 负责大模型应用项目的需求分析、技术选型、架构设计及工程落地，推动业务需求转化为可实施的算法与系统方案。
2. 建立模型与系统效果评测流程，围绕准确性、检索效果、工具调用成功率、响应延迟及稳定性持续开展优化。
3. 针对模型幻觉、上下文丢失、工具调用错误和高延迟等问题进行分析与优化，持续提升系统可用性。

项目经历

技术栈 Hermes Agent、OpenClaw、MCP、Skills、A2A、Prompt Engineering、BGE-M3、Milvus、Qwen、FunASR、CosyVoice、WebRTC、ECharts

● 项目简介

面向 K12 学校及教育机构的课后教学场景，构建校本知识库、教师智能助手和学生个性化辅导平台。教师依据班级教学进度生成练习、分析学情并安排干预；学生通过学校开通的平台进行课后提问、数字人讲解和掌握检验。学习结果回流教师端，形成“教师布置-学生学习-系统诊断-教师干预”的教学闭环。

● 核心工作

1. 引入 Hermes Agent 构建教学智能体运行架构，将知识答疑、错题诊断、练习生成和学习规划封装为可组合的 Skills，支持按问题类型动态选择教学策略；结合会话、学生学情、班级进度和长期学习记录管理辅导上下文，通过教学 Prompt 模板与 Few-shot 示例规范讲解和错因分析。
2. 基于 MCP 标准化改造工具调用体系，将知识检索、错题查询、学情分析和题目匹配封装为统一工具服务，供学生辅导 Agent 与教师助手复用；统一参数校验与返回格式，并通过身份和班级权限限制数据访问范围，保证跨 Agent 调用的一致性。
3. 建设按学校、年级、教材版本、章节和知识点组织的教学知识库，使用 BGE-M3 向量化与 Milvus 语义检索匹配讲解资料和相似题目；结合元数据过滤与结果校验限制错误召回，同时保留资料来源与知识点关联，供讲解内容和检验题复核。
4. 设计教师端 OpenClaw 智能助手，覆盖备课出题、班级学情分析和即时问答场景；动态注入教师所授班级、教学进度及校本资料，叠加教学安全约束，并加入内容审核、超时降级和本地模板兜底机制，支持教师修改后发布。
5. 基于 A2A 协议实现教学 Agent、检索 Agent、评价 Agent 与教师助手的跨服务协作，设计 Agent Card 服务发现、JSON-RPC 消息转发和任务 Handoff 机制；增加循环检测、超时重试及失败回退，记录调用轨迹以定位重复调度和工具异常。
6. 打通 FunASR → 教学 Agent/RAG → Qwen → CosyVoice → 数字人的语音辅导链路，支持学生语音提问、分段语音讲解及 WebRTC 数字人呈现；讲解后生成检验题，根据作答结果调整讲解方式并更新学情档案，数字人不可用时保留文字讲解。
7. 建设教师端学情看板，使用 ECharts 展示班级薄弱知识点、高频错因、练习完成情况及学生掌握变化，支持教师定位需人工干预的学生并发布针对性练习；保留知识点钻取和原始答题记录，使教学建议能够追溯。

● 项目成果

1. 打通“教师布置-学生提问-个性化讲解-掌握检验-学情回流”的课后辅导流程，将学生的高频问题和检验结果汇总给教师，支持教师集中处理班级共性问题。
2. 将学生每次辅导的卡点、作答结果和后续练习关联到学情档案，帮助教师发现需要个别干预的学生，并安排针对性练习。
3. 建立“同知识点二次检验通过率”作为辅导效果指标，统计学生接受针对性讲解后再次作答的通过情况，供教师判断讲解是否有效、是否需要调整练习。

通用 Agent 任务拆解与工具选择能力微调

2025.10 - 2026.02

技术栈 LoRA、QLoRA、AQLoRA、PyTorch、Transformers、CUDA、RTX 4090、Python

● 项目简介

面向通用 Agent 任务规划与工具调用场景，针对大模型任务拆解不完整、工具选择错误及子任务匹配不准确等问题，构建任务规划与工具调用指令微调数据，并采用 LoRA 量化微调方案优化模型能力，提高 Agent 执行复杂用户需求时的稳定性与工具选择准确率。

● 核心工作

1. 围绕 Agent 的任务拆解与工具选择场景构建训练数据，输入内容由用户需求和可用工具描述组成，输出内容包括任务拆解结果及对应工具选择结果，覆盖单工具调用、多工具协同及复杂任务分解等类型。
2. 对训练数据进行统一格式设计，使模型能够根据用户目标识别子任务、判断任务之间的执行关系，并为不同子任务匹配对应工具。
3. 分别选取 14B 和 32B 参数规模模型开展微调实验，基于 RTX 4090 GPU 训练环境，采用 QLoRA 及 AQLoRA 方案降低训练资源需求，训练轮次控制在 3-5 轮，对比不同模型规模和微调方案下的工具调用表现。
4. 针对大模型微调过程中出现的显存溢出（OOM）问题，通过降低 Batch Size、缩短最大序列长度以及采用多卡训练等方式控制显存占用，保障训练任务稳定运行。

5. 对微调前后模型在任务拆解完整性、工具选择正确性及输出格式稳定性等方面进行对比，重点分析遗漏子任务、误选工具和工具重复调用等错误类型，并根据错误样本持续调整训练数据。

● 项目成果

1. 完成面向 Agent 任务规划和工具调用场景的专项微调，使模型能够按照“用户需求分析-任务拆解-工具匹配”的流程输出结构化执行方案。

企业法律智能 Agent 系统

2025.03 - 2025.09

技术栈 LangChain、LangGraph、RAGFlow、DeepDoc、MinerU、PDF Parser、Qwen-VL、BGE、BM25、Reranker、FAISS、Text2SQL、LightRAG、Neo4j、WebSearch、Python

● 项目简介

面向企业法务用户搭建智能法律服务系统，根据用户的案件类型、业务场景、风险等级及咨询偏好，提供法律方案生成、事务流程规划、法规推荐、法条定位及实时信息检索等服务，提升法律事务处理效率与问答体验。

● 核心工作

1. 负责法律 Agent 整体方案设计，接入 RAG、Text2SQL、知识图谱三类核心能力，以及法规查询、法条定位和 WebSearch 联网搜索工具；由 Agent 对用户问题进行意图识别和任务拆解，并根据问题类型选择相应工具完成回答。
2. 设计多源数据处理流程，使用 RAGFlow 中的 DeepDoc、MinerU 处理 PDF 等非结构化文档，通过 PDF Parser 解析表格内容，并利用 Qwen-VL 对图片进行识别和结构化描述，为后续知识入库与检索提供高质量数据。
3. 根据不同文档结构和业务场景，综合使用文档结构切分、父子块切分、递归切分、滑动窗口切分及语义切分策略，降低长文档语义割裂和关键信息丢失问题。
4. 搭建 BGE 向量召回与 BM25 关键词召回相结合的多路召回体系，并通过全局 Reranker 对候选内容进行精排，提升复杂法律问题下的知识召回效果和上下文相关性。
5. 根据不同问题类型设计工具路由策略：RAG 负责法规解读、法律建议等非结构化知识问答；Text2SQL 负责金额排序、预算比较和案件统计等结构化数据查询；知识图谱负责主体归属、法律关系及关联案件等关系型问题。
6. 引入 Qwen-VL 多模态能力，使系统能够理解用户上传的合同、票据及法律相关图片，并结合图片内容与用户问题生成相应回答。
7. 构建用户画像机制，记录用户对案件类型、风险偏好、预算及处理方式等偏好，使系统能够生成更符合个体需求的法律推荐和事务处理方案。
8. 通过 WebSearch 补充最新法规、司法解释及政策动态等时效性信息，弥补本地知识库更新不及时的问题。

● 项目成果

1. 通过文档清洗、分块策略优化、多路召回及 Reranker 精排，将自建测试集的核心知识召回率由 83% 提升至 93%，显著改善复杂问题下的检索与回答效果。
2. 实现 RAG、Text2SQL、知识图谱和实时搜索能力的统一调度，使系统能够同时处理普通知识问答、关系查询、金额分析及实时信息查询等多类法律需求。
3. 构建动态思路库，持续沉淀复杂意图下的任务拆解、工具选择和回答策略，为后续优化 Agent 工具调用准确性及问答质量提供支持。

法律领域私有化大模型微调

2024.09 - 2025.01

技术栈 LLaMA-Factory、LoRA、Qwen、Baichuan、GLM、ROUGE、BLEU、PyTorch、Transformers、Python

● 项目简介

针对通用大模型在法律领域存在的专业术语识别不准确、行业知识覆盖不足以及回答风格不够专业等问题，对开源大模型进行领域微调，提升模型在法律法规、合同审查及行业知识问答等场景中的专业性与回答准确性，为法律业务提供可私有化部署的模型能力。

● 核心工作

1. 参与法律领域微调方案设计，围绕专业术语理解、行业知识问答和回答风格优化等目标，完成领域数据整理、指令数据构造、模型训练及效果评估。
2. 基于 LLaMA-Factory 微调框架，采用 LoRA 参数高效微调方法，对 Qwen、Baichuan、GLM 等 6B/7B 规模模型开展训练与对比实验，筛选适合法律问答场景的基础模型及训练方案。
3. 对法律领域语料进行清洗和整理，构造包含用户问题、标准回答及任务指令的微调数据，增强模型对法规名称、司法案例、合同条款等专业内容的理解能力。

4. 针对领域微调后可能出现的灾难性遗忘问题，在训练数据中合理混合法律领域数据与通用语料，调整两类数据的配比，兼顾领域知识增强与模型通用对话能力。
5. 使用 ROUGE、BLEU 等自动化指标进行辅助评估，同时采用人工盲测方式，从事实准确性、内容完整性、专业程度和表达自然度等维度评估模型效果，并根据错误样本持续调整训练数据与微调策略。

● 项目成果

1. 微调后的模型在人工盲测中取得 86% 的回答合格率，提升了模型在法律专业知识问答、领域术语理解及行业表达方面的能力。
2. 缓解通用大模型在法律场景中知识匹配不准确、回答内容泛化及表达不够专业等问题，为后续法律智能问答和 Agent 系统提供领域模型能力支持。

景区数字人语音导览问答系统

2024.02 - 2024.07

技术栈 RAG、ASR、TTS、Live2D、FastAPI、WebSocket、Python

● 项目简介

面向景区智能咨询与导览场景，在传统 RAG 知识问答基础上引入 ASR 语音识别、TTS 语音合成和 Live2D 二维数字人能力，将景区知识检索、语音交互与数字人导游展示进行整合，提升游客咨询效率、交互自然度和游览体验。

● 核心工作

1. 参与景区数字人语音导览问答系统的方案设计与功能开发，在景区知识检索与答案生成基础上，集成 ASR、TTS 和 Live2D 数字人模块，搭建端到端语音问答链路。
2. 接入 ASR 语音识别能力，将游客输入的语音实时转换为文本，并将识别结果传递至 RAG 问答模块，降低游客手动输入成本。
3. 搭建景区 RAG 知识问答流程，围绕景点介绍、历史文化、开放时间、游览规则和交通指引等资料建立知识库，根据游客问题检索相关内容并生成准确、连贯的回答。
4. 接入 TTS 自然语音合成能力，将 RAG 生成的文本答案转换为语音进行播放，实现从游客语音输入到系统语音回答的完整交互闭环。
5. 集成 Live2D 二维数字人导游，将景点介绍和问答结果通过数字人形象进行语音播报，增强景区导览服务的可视化表现和沉浸式体验。
6. 对 ASR、RAG、TTS 和 Live2D 各模块进行接口联调，重点处理语音识别结果传递、景区答案生成、语音播放及连续多轮旅游咨询过程中的链路衔接问题。

● 项目成果

1. 完成 ASR 语音识别-RAG 景区知识检索-答案生成-TTS 语音合成-Live2D 数字人导游播报的端到端链路，实现由文字问答向语音数字人导览方式的升级。
2. 在测试环境下，将 ASR 单模块识别延迟控制在 0.5 秒以内，为系统实时语音交互提供基础支持。
3. 实现游客通过自然语音与景区知识库进行交互，并由 Live2D 数字人导游完成回答播报，提升旅游咨询的交互自然度和景区内容呈现效果。

文旅营销文案智能创作系统

2023.10 - 2024.01

技术栈 大模型 API、Prompt、多候选生成、模板库、CTR 数据分析、人工审核、Python

● 项目简介

针对旅游文案人工创作效率低、内容同质化严重以及优质文案难以规模化复用等问题，从 0 到 1 搭建旅游文案智能生成系统。通过提示词工程、候选文案生成、模板管理和人工审核机制，辅助运营人员高效产出具有吸引力且符合业务要求的旅游文案。

● 核心工作

1. 负责旅游文案生成系统从 0 到 1 的方案设计与功能开发，围绕景点宣传、旅游攻略、活动推广及投放渠道等场景完成生成流程设计、提示词优化和系统功能迭代。
2. 设计多候选文案生成机制，根据同一旅游主题一次生成多个不同表达版本，由运营人员结合内容质量和业务需求选择最终文案，降低单次生成结果不稳定对上线内容的影响。
3. 通过提示词工程约束文案主题、表达风格、内容结构及目标人群，减少内容偏题、表达重复和营销亮点不足等问题，提升生成文案的可用性。
4. 建立旅游文案模板库，沉淀不同景点类型、推广场景和表达风格下的提示词模板；根据人工审核结果保留高质量模板，对效果较差的模板进行修改或下线。
5. 上线后持续跟踪不同模板对应文案的 CTR 表现，保留高点击率模板，并持续优化点击率较低、内容同质化明显的模板。

6. 引入人工审核与选择机制，对候选文案的事实信息、表达质量及上线适用性进行确认，在提升生成效率的同时保障最终输出质量。

● 项目成果

1. 完成旅游文案从需求输入、多候选内容生成、人工筛选到最终发布的标准化生产流程，提升文案生产效率，降低重复性人工创作成本。
2. 建立可持续迭代的文案模板库，形成基于人工反馈和 CTR 表现进行模板筛选、优化与下线的闭环机制。
3. 缓解不同景点和推广场景下文案表达同质化的问题，为旅游内容的规模化生产与复用提供系统支持。

景区宣传视觉素材 AIGC 系统

2023.05 - 2023.09

技术栈 Stable Diffusion、LoRA、ControlNet、OpenPose、Depth、Canny、BLIP、Kohya_ss、图生图、局部重绘

● 项目简介

面向景区宣传推广场景，基于 Stable Diffusion 搭建景区海报智能生成系统，通过文生图和图生图两种方式，根据景区自然景观、历史文化、活动主题及投放渠道生成宣传海报，提升景区视觉素材的生产效率与风格多样性。

● 核心工作

1. 基于 Stable Diffusion 搭建景区宣传海报生成系统，实现文生图与图生图能力，支持地铁灯箱、广告牌、宣传展板及明信片等多种宣传场景。
2. 针对 BLIP 自动标注细节不足的问题，对主体特征、场景、构图及风格标签进行人工补充，提升训练数据描述完整性。
3. 使用 ControlNet OpenPose、Depth、Canny 分别控制人物姿态、空间关系及主体轮廓，改善手部异常、景深错误和景观结构变形等问题。

● 项目成果

1. 实现景区宣传海报的文生图和图生图功能，可根据景区名称、宣传主题及风格要求直接生成海报，也可基于景区原图生成新的宣传素材。
2. 支持写实、二次元等多种视觉风格切换，同一张景区图片可快速生成不同风格的海报方案，供运营和设计人员选择。

游客评论多维情绪洞察系统

2022.12 - 2023.04

技术栈 BERT-Base、Word2Vec、BiLSTM、SVM、Stacking、逻辑回归、规则库、Python、PyTorch

● 项目简介

面向旅游平台和景区运营场景，对游客发布的游玩评论进行评价维度识别和情感极性判断，覆盖景观体验、服务质量、基础设施、交通便利性及票价性价比，帮助运营人员快速定位主要表扬点与投诉问题。

● 核心工作

1. 参与制定景区评论标签体系，按景观体验、服务质量、设施环境、交通便利性和票价性价比划分评价维度，并标注正向、中性和负向情感。
2. 负责景区游玩评论的去重、清洗和标签复核，完成训练、验证与测试集划分，并通过抽样质检统一标注口径。
3. 以 Word2Vec+SVM 和 BiLSTM 为基线，微调 BERT-Base，并在相同数据划分和评估口径下比较模型效果。
4. 针对反讽、转折、正负情感混合和少样本类别整理 Bad Case，补充困难样本，并结合规则库修正明显冲突。
5. 使用逻辑回归对 BERT-Base、BiLSTM 和 SVM 的预测结果进行 Stacking 融合，并接入每日新增评论分析任务。

● 项目成果

1. 实现景区评价维度与情感极性的自动识别，按周汇总各维度的情感分布和典型投诉，供运营人员快速定位景区服务问题。
2. 相较优化前版本的 91%，融合方案在固定测试集上的联合分类准确率达到 97%，主要改善反讽、转折和少样本类别。

技术栈 BERT、BiLSTM、CRF、BIOES、领域词典、别名归一化、Python、PyTorch

● 项目简介

面向旅游智能问答场景，从用户自然语言问题中识别城市、景点、酒店、餐饮、交通方式、时间及人群等关键信息，并将非结构化问题转换为结构化数据，为知识图谱查询、RAG 检索、路线规划和个性化推荐等下游模块提供输入。

● 核心工作

1. 参与梳理旅游领域实体类别和 BIOES 标注规范，统一城市、景点、酒店、餐饮、交通方式、时间及人群等实体的边界和类型标注口径。
2. 负责用户搜索日志、旅游咨询问答和旅游攻略等数据的清洗与预标注，通过人工复核和抽样质检构建训练、验证和测试数据集。
3. 以 BiLSTM-CRF 为基线，对比 BERT-CRF 与 BERT-BiLSTM-CRF，最终采用 BERT-BiLSTM-CRF 方案。
4. 根据实体边界截断、景点别名、口语表达和上下文歧义等 Bad Case 补充困难样本，并使用实体保持型替换进行数据增强。
5. 结合旅游领域词典进行边界修正和别名归一化，输出实体类型、位置、原始文本及标准景点 ID。

● 项目成果

1. 相较 BiLSTM-CRF 基线的 87%，最终抽取链路在测试集上的实体级 F1 达到 93%，并改善长实体边界和景点别名识别。
2. 实现旅游实体的自动抽取与标准化，为知识图谱、RAG、路线规划和推荐系统提供稳定的结构化参数。

教育背景

2018.9 - 2022.6

郑州科技学院

计算机科学与技术（本科）

自我评价

- 学习能力和新技术接受能力较强，能够快速理解业务需求并推动项目落地。
- 擅长沟通协作，性格随和、情绪稳定，具备较强的责任心和问题解决意识。
- 平时喜欢旅游和探索美食，乐于接触新事物，能够较快融入团队。